

Demand Forecasting and Inventory Optimisation Using Machine Learning

A simulation-based evaluation on the M5-Forecasting (Walmart) dataset, with an SME-accessible Power BI dashboard.

Desmond Korbla Aziege | Theresa Korlekuor Apla-Kweku | Abdul-Razak Seidu

Supervisor: Prof. Rocío González Martínez

Abstract

Retail demand forecasting and inventory optimisation are central to operations management, yet the operational value of machine-learning forecasting is more often asserted than measured. This thesis develops and evaluates an end-to-end forecasting-to-inventory framework on the M5-Forecasting (Walmart) dataset — a stratified subsample of 502 product–store series of daily, intermittent SKU-level demand — comparing classical statistical baselines, gradient-boosting and deep-learning models, a stacking ensemble, and LightGBM quantile regression, and integrating their outputs with a periodic (R, s, S) Order-Up-To-Level inventory policy. On forecast accuracy, the stacking ensemble is the most accurate model but improves on the strongest classical baseline by only about 4.5% (MAE), well below the 10–25% reported in prior work. Critically, when inventory outcomes are measured by forward simulation over the real test window rather than assumed, all policies achieve full service with no stockouts, so neither the more accurate point forecast nor a quantile-based safety-stock reformulation lowers inventory cost: the apparent saving reported under assumed service levels does not survive measurement. The thesis interprets this as a finding rather than a failure. The 10–25% and 5–15% benchmarks of the literature were obtained on aggregated data and do not transfer to SKU-daily intermittent demand, and the operational value of ML forecasting is conditional on the demand regime, material only where the baseline policy faces genuine stockout risk. The contribution is a rigorous, reproducible, simulation-based characterisation of when ML forecasting and distributional safety stock affect inventory outcomes, delivered through an accessible Power BI dashboard designed for SME retailers.

Keywords: demand forecasting; machine learning; inventory optimisation; intermittent demand; inventory simulation; safety stock; quantile regression; Order-Up-To-Level (R, s, S) policy.

Resumen

La previsión de la demanda y la optimización de inventario son centrales en la gestión de operaciones del comercio minorista, pero el valor operativo de la previsión basada en aprendizaje automático se suele afirmar más que medir. Esta tesis desarrolla y evalúa un marco integral de previsión e inventario sobre el conjunto de datos M5-Forecasting (Walmart) — una submuestra estratificada de 502 series producto–tienda de demanda diaria, intermitente y a nivel de SKU — comparando modelos estadísticos clásicos, modelos de gradient boosting y aprendizaje profundo, un ensemble por apilamiento (stacking) y regresión cuantílica con LightGBM, e integrando sus salidas con una política periódica (R, s, S) de nivel de reposición (Order-Up-To-Level). En precisión de previsión, el ensemble es el modelo más preciso, pero mejora al mejor modelo clásico en apenas un 4,5% (MAE), muy por debajo del 10–25% reportado en trabajos previos. De forma decisiva, cuando los resultados de inventario se miden mediante simulación hacia delante sobre la ventana de test real, en lugar de asumirse, todas las políticas alcanzan servicio completo sin roturas de stock, de modo que ni la mayor precisión de la previsión ni la reformulación cuantílica del stock de seguridad reducen el coste de inventario: el ahorro aparente obtenido bajo niveles de servicio asumidos no sobrevive a la medición. La tesis interpreta esto como un hallazgo, no como un fracaso. Los umbrales del 10–25% y del 5–15% de la literatura se obtuvieron sobre datos agregados y no se trasladan a la demanda intermitente a nivel SKU-día, y el valor operativo de la previsión con ML es condicional al régimen de demanda, relevante solo cuando la política base se expone a un riesgo real de rotura. La contribución es una caracterización rigurosa, reproducible y basada en simulación de cuándo la previsión con ML y el stock de seguridad distribucional afectan a los resultados de inventario, presentada mediante un cuadro de mando accesible en Power BI diseñado para pymes minoristas.

Palabras clave: previsión de la demanda; aprendizaje automático; optimización de inventario; demanda intermitente; simulación de inventario; stock de seguridad; regresión cuantílica; política Order-Up-To-Level (R, s, S).